

# ГЕНЕТИЧЕСКИЙ АЛГОРИТМ ДЛЯ НАСТРОЙКИ ПАРАМЕТРОВ АЛГОРИТМОВ ADAS

Матвеева Татьяна, студентка 3 курса, st086841@student.spbu.ru  
Осечкина Мария Сергеевна, инженер-программист АО "Кама"  
Литвинов Юрий Викторович доцент кафедры системного  
программирования, к.т.н

## Аннотация

Advanced Driver-Assistance Systems — системы помощи водителю, которые в настоящее время активно интегрируются в автомобили. Архитектура ADAS подразумевает наличие датчиков (лидары, радары, камера). Данные, полученные с лидаров могут быть кластеризованы и использованы в дальнейшем как обучающая выборка для алгоритмов машинного обучения.

В данной работе предполагается разработать решение для задачи подбора гиперпараметров в алгоритмах кластеризации лидарных данных с помощью генетического алгоритма.

## Введение

ADAS [5] (Advanced Driver-Assistance Systems) — системы помощи водителю, которые в настоящее время активно интегрируются в автомобили. Основной их задачей является ассистирование в сложных ситуациях, возникающих во время движения. Архитектура ADAS подразумевает наличие датчиков (лидары, радары, камера), процессора восприятия, где происходит распознавание семантики и основного контроллера, принимающего решения относительно действий системы на основании результата работы процессора восприятия.

В рамках работы будут рассмотрены алгоритмы кластеризации данных, полученных с лидара из датасета a2d2 [1], который представляет собой набор снимков камер, установленных на автомобиле с соответствующими им облаками точек и датасета SemanticKitty [7], который представлен как последовательность облаков точек с соответствующей им семантической разметкой.

Установка датчика типа лидар на автомобиль делает этот автомобиль дороже в несколько раз, поэтому наиболее популярным решением в данной области являются камеры. Как бы то ни было, алгоритмы

ADAS требуют семантической разметки кадров, что на данный момент реализуется непосредственно во время движения автомобиля с помощью нейронных сетей. Для обучения модели такой нейронной сети необходимо создать тестовую выборку с верной семантической разметкой, для чего и могут быть использованы автоматически кластеризованные облака точек, отображенные на изображения камер.

Цель этой работы — внедрение генетического алгоритма для автоматизации выбора гиперпараметров различных алгоритмов кластеризации для облаков точек.

## Алгоритмы кластеризации

В этом разделе будут рассмотрены два наиболее известных алгоритма кластеризации DBSCAN и KMeans.

### *DBSCAN*

Алгоритм DBSCAN [2] — плотностной алгоритм пространственной кластеризации с присутствием шума. Алгоритм удобен тем, работает без предварительного обучения. Широко используется во многих областях анализа данных. Все рассматриваемые точки в результате работы будут разделены на внутренние, граничные и шум. *Радиус окрестности* для определения границ кластера является параметром алгоритма и должен быть определён пользователем, так же как и *минимальное число точек* в окрестности рассматриваемого объекта, чтобы считать его точкой кластера.

### *Kmeans*

Kmeans [6] — итеративный алгоритм, который разделяет данные на  $K$  непересекающихся групп. Он определяет точку в кластер таким образом, чтобы сумма квадратов расстояний между точками в кластере и центром была наименьшей. Гиперпараметрами алгоритма являются *количество кластеров*, *расположение центров* и *количество итераций*. В отличие от алгоритма DBSCAN, логика Kmeans основывается на определении расстояния между точками облака, а не на плотности их распределения. Хотя такой подход может приводить к неверному определению ленточных кластеров, как показано на рис. 1, иногда в

литературе встречаются примеры [4], иллюстрирующие преимущества работы Kmeans над DBSCAN при кластеризации облаков точек.




Рис. 1: Сравнение алгоритмов DBSCAN и Kmeans

## Генетический алгоритм

Генетический алгоритм представляет собой имитацию естественного отбора и состоит из нескольких последовательных операций, которые представлены на рис. 2. В качестве генов используются переменные для оптимизации.

Одной из важных составляющих алгоритма является *функция приспособленности* — метрика для оценки кандидата (отдельного элемента популяции). Исходя из значений функции можно судить о корректности выбранных параметров, поэтому верный ее выбор является важным шагом при разработке алгоритма.




Рис. 2: Этапы генетического алгоритма

## Метрика оценки выбранных гиперпараметров

Чтобы автоматически оценивать подобранные алгоритмом параметры, было решено ввести специальную референсную метрику. Принцип работы метрики состоит в следующем:

- для каждого кластера из облака, кластеризованного с помощью алгоритма, вычисляется соответствующий кластер в облаке с правильной разметкой
- для выбранных кластеров считается коэффициент IoU

Метрика для каждого облака считается как среднее по всем кластерам. Значение метрики для последовательности кадров считается как среднее значение по последовательности. На рисунках 3 и 4 можно зависимость IoU от подобранных параметров кластеризации.




Рис. 3:  $\text{IoU} = 0.89$



Рис. 4:  $\text{IoU} = 0.63$

## Алгоритм

Рассмотрим отдельно наиболее содержательные пункты реализации генетического алгоритма для лидарных данных.

### *Предобработка данных*

Для гарантии сходимости алгоритма к наилучшим параметрам по функции приспособленности было принято решение модифицировать входные данные. На время работы функции приспособленности оставить в облаке только необходимые объекты — точки, находящиеся непосредственно над предполагаемой дорогой (пример такого преобразования показан на рис. 5, 6).




Рис. 5: Облако до преобразования




Рис. 6: Облако после преобразования

Благодаря такому преобразованию шум, возникающий при кластеризации объектов вне проезжей части, не будет препятствовать вычислению верной оценки кадра.

### *Функции приспособленности*

В качестве функций приспособленности использовались как стандартные метрики, существующие в предметной области, так и самостоятельно сконструированный коэффициент для измерения качества кластеризации:

- CrowdWisdom

Метрика основана на принципе «мудрость толпы»[3]. Расстановка коэффициентов перед значениями метрик вызвана необходимостью нормализовать области значений функций.

$$CrowdWisdom(X) = S(X) + \frac{1}{DB(X)} - \frac{1}{CH(X)}$$

где  $X$  — метки, полученные в результате кластеризации,  $S$  — метрика Silhouette,  $DB$  — метрика Davies-Bouldin,  $CH$  — метрика Calinski-Harabasz.

Перечисленные метрики наиболее популярны в предметной области.

## Предварительные результаты

Эксперименты проводились на данных датасета [7] для последовательности из 25 облаков. Количество хромосом в поколении генетического алгоритма было установлено равным 15, количество поколений – 10. Проверка результатов проведена с помощью разработанной метрики IoU, максимальное значение является наилучшим и равно 1. Алгоритм DBSCAN

Метрики	Параметры	IoU
Silhouette	(0.66, 14)	0.7499
Calinski-Harabaz	(0.3429, 1)	0.8402
Davies-Bouldin	(0.7469, 1)	0.8062
<b>CrowdWisdom</b>	(0.638,1)	0.855

Таблица 1: Результаты на рассмотренных метриках

Алгоритм Kmeans

Метрики	Параметры	IoU
Silhouette	(21, 327, 10)	0.617
Calinski-Harabaz	(30, 305, 14)	0.297
<b>Davies-Bouldin</b>	(99, 396, 14)	0.788
CrowdWisdom	(30, 341, 9)	0.771

Таблица 2: Результаты на рассмотренных метриках

## Заключение

Таким образом, в результате работы были рассмотрены различные алгоритмы кластеризации и метрики для них, в том числе разработанный коэффициент *CrowdWisdom*. Также были проведены эксперименты по подбору гиперпараметров для двух наиболее известных алгоритмов кластеризации — Kmeans и DBSCAN, в результате которых было установлено, что алгоритм DBSCAN лучше справляется с задачами, возникающими в предметной области, а метрика *CrowdWisdom* может быть использована в качестве функции приспособленности в генетическом алгоритме.

## Список литературы

- [1] A2D2: Audi Autonomous Driving Dataset / Jakob Geyer, Yohannes Kassahun, Mentar Mahmudi et al. — 2020. — 2004.06320.
- [2] ADBSCAN: Adaptive Density-Based Spatial Clustering of Applications with Noise for Identifying Clusters with Varying Densities / Mohammad Mahmudur Rahman Khan, Md. Abu Siddique, Rezoana Arif, Mahjabin Oishe. — 2018. — 09.
- [3] Alizadeh Hosein, Yousefnezhad Muhammad, Minaei Behrouz. Wisdom of Crowds Cluster Ensemble // Intelligent Data Analysis. — 2015. — 06. — Vol. 19.
- [4] Florent Poux Ph.D. 3D Point Cloud Clustering Tutorial with K-means and Python // Towards Data Science. — URL: <https://towardsdatascience.com/3d-point-cloud-clustering-tutorial-with-k-means-and-python-c870089f>
- [5] Jayan Keerthi, Muruganantham B. Advanced Driver Assistance System Technologies and Its Challenges Toward the Development of Autonomous Vehicle // Intelligent Computing and Applications / Ed. by Subhransu Sekhar Dash, Swagatam Das, Bijaya Ketan Panigrahi. — Singapore : Springer Singapore, 2021. — P. 55–72.
- [6] Li Youguo, Wu Haiyan. A Clustering Method Based on K-Means Algorithm // Physics Procedia. — 2012. — Vol. 25. — P. 1104–1109. — International Conference on Solid State Devices and Materials Science, April 1-2, 2012, Macao. URL: <https://www.sciencedirect.com/science/article/pii/S1875389212006220>.
- [7] Towards 3D LiDAR-based semantic scene understanding of 3D point cloud sequences: The SemanticKITTI Dataset / J. Behley, M. Garbade, A. Milioto et al. // The International Journal on Robotics Research. — 2021. — Vol. 40, no. 8-9. — P. 959–967.